

Tabela 1: Perfil de Paciente

1. O que é essa tabela e pra que ela serve

Essa tabela é o resultado da minha parte no projeto (camada de dados e estatística): pegar a base bruta do SIH-RD (internações do SUS em São Paulo, 2022-2024) e transformar em uma tabela em grão de internação, ou seja, **1 linha = 1 internação que passou por UTI**. São 813.422 linhas.

Ela é a “tabela estrela” pro nível de paciente individual dentro do CLARITI: é o que vai sustentar perguntas de linguagem natural via Select AI sobre perfil de paciente, alimentar o modelo de ML de risco de reinternação, e entrar no dashboard como o pilar “Perfil” do Challenge (quem são os pacientes, não só quantos internam).

2. O que já foi decidido nessa tabela, e por quê

2.1 Por que faltam campos que vocês esperariam ver

Reparem que não tem CPF, nome, data de nascimento completa, nem CEP completo. Isso é decisão deliberada, não esquecimento.

A base bruta do SIH-RD é pública. Se eu deixasse data de nascimento exata + CEP completo + idade exata juntos numa mesma linha, seria possível, cruzando com outras informações, identificar uma pessoa específica de volta (isso é chamado de “quase-identificador”: sozinho não identifica ninguém, mas combinado com outros campos, identifica sim). A ANPD (autoridade de proteção de dados do Brasil) e o padrão internacional HIPAA Safe Harbor tratam esses campos exatamente assim.

A solução que apliquei é **generalização**: trocar precisão por privacidade, mas sem perder o valor analítico que o projeto realmente usa. Na prática: - Data de nascimento completa **saiu**. Em vez dela, entrou `FX_IDADE`, faixa etária de 5 anos (ex: “25-29”), suficiente pra qualquer análise de perfil etário que o grupo for fazer. - CEP completo **saiu**. Município de residência (`CD_MUNICIPIO_RES`) ficou, porque nenhuma análise do projeto precisa de uma geografia mais fina que município. - Data de internação completa **saiu**. Fica só ano e mês (`NR_ANO`, `NR_MES`), mais dia da semana e indicadores de fim de semana/feriado (que têm cardinalidade baixíssima e não identificam ninguém).

2.2 O sinal de reinternação em 30 dias

`FL_REINTERNACAO_30D` marca se aquele paciente provavelmente voltou pra UTI em até 30 dias depois de uma alta anterior. É um indicador clássico de qualidade em saúde: reinternação evitável em pouco tempo geralmente aponta falha de acompanhamento (atenção primária), que é exatamente a tese central do projeto.

Como isso foi calculado sem ter CPF: usei data de nascimento + sexo + CEP juntos, só internamente, como uma espécie de “impressão digital” temporária pra tentar reconhecer quando a mesma pessoa aparece em duas internações diferentes. Essa impressão digital nunca vai pro banco de dados, ela é descartada assim que o cálculo termina, sobra só o resultado (`FL_REINTERNACAO_30D` e `QT_INTERNACOES_PERIODO`).

Isso é uma **estimativa**, não um fato certo, porque não existe CPF na base pública. Duas pessoas diferentes podem, por coincidência, compartilhar essa “impressão digital”, e é exatamente esse problema que a seção abaixo explica.

2.3 Colisão de chave: o que é, e o que eu encontrei

Explicando o termo antes de explicar o achado: **“chave”**, aqui, é o nome técnico pra essa “impressão digital” que citei acima (data de nascimento + sexo + CEP juntos). **“Colisão”** é quando duas coisas diferentes, que deveriam ser distintas, acabam caindo no mesmo lugar por coincidência. Então **“colisão de chave”** é isso: duas pessoas DIFERENTES que, por acaso, têm exatamente a mesma data de nascimento, o mesmo sexo e o mesmo CEP, e por isso o sistema as trata erroneamente como se fossem uma pessoa só.

Como eu descobri isso: ao validar a tabela, encontrei um “paciente” com 67 internações de UTI contadas entre 2022 e 2024. Pra uma pessoa real, isso significaria ficar internado em UTI e sair de novo a cada ~16 dias, sem parar, por quase 3 anos seguidos, o que não é plausível.

Antes de concluir que era colisão, testei duas explicações mais específicas primeiro (elas seriam achados mais interessantes se fossem verdade): 1. **Seria um valor padrão/genérico?** Tipo um sistema que usa uma data “coringa” quando não sabe o dado real de um paciente sem documento. Testei: se fosse isso, essa mesma data apareceria espalhada por milhares de “pacientes” diferentes pela base inteira. Não é o que acontece, ela aparece quase só dentro desse um grupo. Descartado. 2. **Seria uma única internação longa, faturada em pedaços mensais?** O sistema público de saúde às vezes fatura uma internação muito longa mês a mês, o que poderia gerar várias linhas pra uma internação só. Testei usando o próprio campo oficial que marca isso no SIH-RD (`IDENT`), e nenhuma dessas linhas suspeitas tinha essa marcação. Descartado também.

Sobrou a explicação mais simples: são pessoas diferentes de verdade, que só coincidem nesses três dados. Isso afeta 3.059 linhas de 813.422 (0,38% da base), pequeno mas real.

O que fiz a respeito: em vez de jogar fora essas 3.059 linhas inteiras (o resto da informação delas, tipo município, diagnóstico, custo, continua válido e correto), marquei uma coluna nova (`FL_COLISAO_CHAVE_SUSPEITA`) e deixei em branco (nulo) só os dois campos que dependem dessa “impressão digital” duvidosa (`FL_REINTERNACAO_30D` e `QT_INTERNACOES_PERIODO`) nessas linhas específicas. O resto da linha continua 100% utilizável.

3. Dicionário de dados

Tabela sugerida: `TB_PERFIL_PACIENTE_UTI` (nome de sugestão, ajustem se já tiverem um padrão fechado). Fonte: `perfil_paciente_sp_2022_2024.parquet`, 813.422 linhas.

Convenção de nome de coluna usada abaixo (prefixo por tipo): `CD_` código, `NM_` nome, `DS_` descrição, `FX_` faixa, `FL_` flag booleano, `QT_` quantidade, `VL_` valor monetário, `NR_` número, `IN_` indicador categórico, `ID_` identificador.

Nome da Coluna	Tipo de Dados	Tamanho/Precisão	Escala	Não Nulo	Chave Primária	Chaves Estrangeiras	Constraints/Condição	Default	Comentário
<code>ID_INTERNACAO</code>	NUMBER	10	-	Sim	Sim	-	-	Sequence/Identity na carga	Coluna nova, não existe no parquet. Sem identificador de paciente (removido de propósito por LGPD, ver seção 2.1), não sobra chave natural. Sugestão de chave substituta pra quando a tabela for criada no Oracle — ver seção 4.
<code>CD_MUNICIPIO_RES</code>	VARCHAR2	6	-	Sim	Não	Possível FK pra dimensão de município, se existir — ver seção 4	6 dígitos, código IBGE truncado	-	Município de residência. CEP completo foi descartado (quase-identificador de alto risco), este é o nível de geografia que sobrou.
<code>CD_DIAG_PRINC</code>	VARCHAR2	4	-	Sim	Não	-	-	‘SEM_DIAG’ quando vazio no bruto	Código CID-10 do diagnóstico principal (campo <code>DIAG_PRINC</code> do SIH-RD). Base da classificação ICSAP.
<code>IN_CSAP</code>	VARCHAR2	3	-	Sim	Não	-	CHECK IN ('sim','não')	-	Indica se o diagnóstico é uma Condição Sensível à Atenção Primária (Lista Brasileira de

									ICSAP). Campo central da tese do projeto.
CD_GRUPO_CSAP	VARCHAR2	3	-	Não (nulo quando IN_CSAP = 'não')	Não	-	CHECK IN ('g01'..'g19') quando preenchido	-	Código do grupo de causa ICSAP (19 grupos, ex: g11 = Insuf. cardíaca).
NM_GRUPO_CSAP	VARCHAR2	60	-	Não (mesma regra acima)	Não	-	-	-	Nome descritivo do grupo ICSAP, acompanha CD_GRUPO_CSAP.
FX_IDADE	VARCHAR2	5	-	Sim	Não	-	Domínio fechado: '0-4'...'85-89','90+'	-	Idade em faixa etária de 5 anos, top-code 90+. NÃO é idade exata (ver seção 2.1).
CD_SEXO	VARCHAR2	1	-	Sim	Não	-	CHECK IN ('1','3') — domínio conferido em toda a base: 447.606 linhas com '1', 365.816 com '3', soma exata, sem outro código, sem nulo	-	Sexo do paciente, código original do SIH-RD, sem alteração.
NR_ANO	NUMBER	4	0	Sim	Não	-	CHECK IN (2022,2023,2024)	-	Ano da internação, extraído antes de truncar a data completa.
NR_MES	NUMBER	2	0	Sim	Não	-	CHECK BETWEEN 1 AND 12	-	Mês da internação. Data completa truncada por LGPD (ver seção 2.1).
DS_DIA_SEMANA	VARCHAR2	8	-	Sim	Não	-	Domínio fechado: segunda..domingo	-	Extraído da data ANTES de truncar pra mês. Mantido por ter cardinalidade baixíssima.
FL_FIM_SEMANA	BOOLEAN*	-	-	Sim	Não	-	-	-	Internação caiu em sábado ou domingo.
FL_FERIADO	BOOLEAN*	-	-	Sim	Não	-	-	-	Internação caiu em feriado nacional ou de SP.
VL_TOTAL	NUMBER	12	2	Sim	Não	-	CHECK (>= 0)	-	Valor total pago pela AIH (campo VAL_TOT do SIH-RD).
QT_DIAS_PERM	NUMBER	5	0	Sim	Não	-	CHECK (>= 0)	-	Dias de permanência da internação.
QT_UTI_MES	NUMBER	3	0	Sim	Não	-	CHECK (>= 0)	-	Dias de UTI no mês de competência. Usado como filtro pra selecionar só internações com UTI.
FL_REINTERNACAO_30D	BOOLEAN*	-	-	Não, nulo de propósito (ver seção 2.3)	Não	-	-	-	Reinternação estimada em até 30 dias (ver seção 2.2). Estimativa, não fato certo.
QT_INTERNACOES_PERIODO	NUMBER	3	0	Não, mesma regra acima	Não	-	CHECK (>= 1) quando preenchido	-	Quantidade de internações da mesma “impressão digital” de paciente, 2022-2024.
FL_COLISAO_CHAVE_SUSPEITA	BOOLEAN*	-	-	Sim	Não	-	-	-	Marca as 3.059 linhas (0,38%) onde a “impressão digital” colidiu entre pessoas diferentes (ver seção 2.3 pra entender o termo e o teste feito).

* BOOLEAN : tipo nativo do Oracle 23ai/26ai (versão que o Challenge já usa). Se preferirem compatibilidade com versão mais antiga, trocar por NUMBER(1) com CHECK IN (0,1) .

Tabela 2: Painel Município x Ano

5. O que é essa tabela e pra que ela serve

Essa é a segunda tabela do dataset: **1 linha = 1 município de São Paulo em 1 ano** (2022, 2023 ou 2024), 645 municípios x 3 anos = 1.935 linhas. Diferente da tabela de perfil de paciente (grão de internação individual), essa é agregada: junta quantidade de internações UTI, quantas delas são ICSAP, capacidade instalada (leitos/estabelecimentos) e investimento público em saúde (SIOPS) por município e ano.

É a tabela que sustenta a tese central do projeto: município que investe mais em atenção primária tem menos internação evitável por UTI depois? Também alimenta o dashboard executivo (ranking de município, mapa regional) e a análise de pressão (demanda x capacidade).

6. Decisões aplicadas nesse painel

Zero de verdade x falta de dado, essa diferença importa: imagine um município pequeno que, num certo ano, não teve NENHUM paciente internado em UTI. Isso é uma informação real (a demanda por UTI ali naquele ano foi zero), bem diferente de “não sei quantos foram” (que seria falta de dado). Se eu tivesse montado a tabela só juntando os registros de internação que existem, um município nessa situação simplesmente sumiria da tabela naquele ano, como se ele não existisse, misturando as duas coisas. Corrigi isso montando primeiro a lista completa dos 645 municípios em cada um dos 3 anos (a partir dos dados de população, que existem pra todo mundo todo ano, independente de ter havido internação), e só depois encaixei os números de internação em cima. Resultado: zero internação aparece como 0 de verdade, e só fica em branco (nulo) quando o dado realmente não existe (leitos/estabelecimentos em município que o CNES não cobriu naquele mês).

Cuidado técnico na conta da capacidade média: cada município tem um valor de leitos/estabelecimentos por mês (12 valores no ano). Só que na tabela de onde tirei isso, esse valor mensal aparece repetido várias vezes (uma vez pra cada diagnóstico diferente daquele mês). Se eu tivesse tirado a média direto em cima de todas essas linhas repetidas, meses com mais diagnósticos diferentes pesariam mais na conta do que meses com menos, distorcendo o resultado sem eu perceber. Por isso reduzo pra um valor só por mês antes de calcular a média entre os 12 meses.

Defasagem do SIOPS (por que investimento de um ano só aparece no ano seguinte): investimento em atenção primária não produz efeito imediato, leva tempo pra impactar a saúde da população. Por isso o investimento SIOPS de um ano (ex: 2022) é associado ao desfecho de saúde do ano SEGUINTE (2023), não do mesmo ano, decisão já debatida e fechada antes dessa etapa. Consequência prática: 2022 no painel fica sem investimento associado (não existe SIOPS de 2021 pra explicar o desfecho de 2022), isso é esperado, não é erro.

Só município de São Paulo entram (o SIOPS só cobre os 645 municípios de SP; internação de residente de fora de SP foi deixada de fora dessa tabela especificamente, embora continue existindo na tabela de origem).

SIOPS tem 4 métricas de despesa mantidas (dotação atualizada, despesa empenhada, liquidada, paga). Não escolhi uma sozinho como “a” variável de investimento pro teste t, isso é decisão de análise. Minha recomendação: `VL_SIOPS_DESPESA_PAGA`, por ser a mais próxima de investimento realizado de verdade (dotação é orçamento previsto, não gasto real).

7. Dicionário de dados do painel

Tabela sugerida: `TB_PAINEL_MUNICIPIO_ANO`. Fonte: `painel_municipio_ano_sp_2022_2024.parquet`, 1.935 linhas. Mesma convenção de prefixo de nome da Tabela 1.

Nome da Coluna	Tipo de Dados	Tamanho/Precisão	Escala	Não Nulo	Chave Primária	Chaves Estrangeiras	Constraints/Condição	Default	Comentário
<code>CD_MUNICIPIO_RES</code>	VARCHAR2	6	-	Sim	Sim (parte 1/2)	Possível FK pra dimensão de município, se existir — ver seção 8	6 dígitos, código IBGE	-	Município (todos os 645 de SP entram, mesmo os sem internação em algum ano).
<code>NR_ANO</code>	NUMBER	4	0	Sim	Sim (parte 2/2)	-	CHECK IN (2022,2023,2024)	-	Ano de referência da linha.
<code>NM_MUNICIPIO</code>	VARCHAR2	60	-	Sim	Não	-	-	-	Nome do município, direto do IBGE.
<code>QT_POPULACAO</code>	NUMBER	9	0	Sim	Não	-	CHECK (>= 0)	-	População do município naquele ano (fonte IBGE).
<code>QT_INTERNAOES_UTI</code>	NUMBER	6	0	Sim	Não	-	CHECK (>= 0)	-	Total de interações com UTI de residentes desse município naquele ano. Zero é valor real (ver seção 6), não falta de dado.
<code>QT_INTERNAOES_ICSA_UTI</code>	NUMBER	6	0	Sim	Não	-	CHECK (>= 0 AND <= QT_INTERNAOES_UTI)	-	Quantas dessas interações são por Condição Sensível à Atenção Primária (ICSA). Indicador central da tese.
<code>VL_TOTAL_UTI</code>	NUMBER	14	2	Sim	Não	-	CHECK (>= 0)	-	Soma do valor pago (AIH) de todas as interações UTI do município no ano.
<code>QT_DIAS_PERM_UTI</code>	NUMBER	8	0	Sim	Não	-	CHECK (>= 0)	-	Soma de dias de permanência de todas as interações UTI do município no ano.
<code>QT_ESTABELECIMENTOS_MEDIA</code>	NUMBER	6	2	Não (nulo quando o CNES não tem dado daquele município-ano)	Não	-	-	-	Média mensal de estabelecimentos de saúde ativos no município naquele ano (CNES).
<code>QT_LEITOS_EXISTENTES_MEDIA</code>	NUMBER	6	2	Não (mesma regra acima)	Não	-	-	-	Média mensal de leitos existentes no município naquele ano (CNES).
<code>QT_LEITOS_SUS_MEDIA</code>	NUMBER	6	2	Não (mesma regra acima)	Não	-	-	-	Média mensal de leitos SUS no município naquele ano (CNES).
<code>VL_SIOPS_DOTACAO_ATUALIZADA</code>	NUMBER	14	2	Não (100% nulo em 2022, de propósito — ver seção 6)	Não	-	-	-	Orçamento previsto de saúde do município no ANO ANTERIOR ao da linha (defasagem de 1 ano).
<code>VL_SIOPS_DESPESA_EMPENHADA</code>	NUMBER	14	2	Não (mesma regra acima)	Não	-	-	-	Despesa empenhada de saúde do ano anterior.
<code>VL_SIOPS_DESPESA_LIQUIDADA</code>	NUMBER	14	2	Não (mesma regra acima)	Não	-	-	-	Despesa liquidada de saúde do ano anterior.
<code>VL_SIOPS_DESPESA_PAGA</code>	NUMBER	14	2	Não (mesma regra acima)	Não	-	-	-	Despesa paga de saúde do ano anterior. Candidata recomendada a variável de investimento no teste t (ver seção 6).

8. O que fica pra vocês decidirem (nas duas tabelas)

Esses três pontos não ficaram faltando por eu não ter terminado. São decisões que dependem de como o resto do modelo relacional/schema está sendo desenhado, ou de material que só quem está com ele tem acesso, e por isso não são minhas pra fechar sozinho:

- ID_INTERNAO** (**chave primária**): como expliquei na seção 2.1, tirei de propósito qualquer coisa que apontasse pra uma pessoa real, então não sobrou identificador natural nessa tabela. Quem for criar o schema físico no Oracle precisa gerar uma chave substituta (um número sequencial sem significado nenhum, só técnico, tipo `SEQUENCE` ou `IDENTITY`). Não é algo que eu deveria inventar aqui, porque depende de como a carga via Airflow vai popular a tabela.
- FK de `CD_MUNICIPIO_RES`**: se já existe (ou vai existir) uma tabela de dimensão de município no banco (por exemplo, vinda dos dados de população do IBGE ou do CNES), esse campo pode virar chave estrangeira apontando pra ela. Isso depende de como o modelo relacional inteiro do banco foi desenhado, então cabe a quem está cuidando da parte de Oracle/ADB decidir e implementar.
- Prefixo de nome de coluna (`CD_`, `NM_`, `FL_` etc)**: usei um padrão comum de nomenclatura, inferido dos dois únicos exemplos que apareceram no material que recebi (`CD_TESTE`, `NM_TESTE`). Se a aula que definiu esse padrão tiver uma lista fechada de prefixos diferente da que usei aqui, quem tiver acesso a esse material completo precisa só ajustar o NOME da coluna — o tipo, o domínio e a constraint de cada campo continuam valendo do jeito que estão. Vale pras duas tabelas.
- Qual métrica de despesa do SIOPS vira “a” variável de investimento no Teste t** (`VL_SIOPS_DESPESA_PAGA`, `_EMPENHADA`, `_LIQUIDADA` ou `_DOTACAO_ATUALIZADA`): deixei as 4 na tabela e recomendei `DESPESA_PAGA`, mas quem for rodar a análise estatística decide de fato, é escolha de método, não de ETL.
- FK de `CD_MUNICIPIO_RES` no painel**: mesma pendência da Tabela 1 — se o grupo já mantém uma dimensão de município no banco, essa coluna vira FK pra ela.